Post-training

Off-Policy and On-Policy Learning

Off-Policy

Definition: a training regime where a language model updates its parameters using externally supplied trajectories (static datasets of prompts and responses) rather than rollouts generated dynamically by its current policy.

Data Source: Human expert demonstrations, synthetic datasets generated by strong teacher models (e.g., GPT-4), or pre-curated preference pairs.

Core Strength:

- **Support Expansion:** Excellent for introducing brand-new capabilities, complex reasoning paths, and formatting constraints that the base model cannot discover on its own.
- **Sample Efficiency & Stability:** Computationally efficient because trajectory generation is decoupled from the training loop; no expensive online generation steps are needed during backpropagation.

Core Weakness

(Distribution Shift): Because the model learns on trajectories it did not generate, it suffers from severe exposure bias. When deployed, small mistakes compound, leading to state distribution shifts where the model encounters states never seen during training and cannot self-correct.

Exposure bias:

- **Bản chất;**
    - Khi huấn luyện (Training): Ở mỗi bước dự đoán từ/token tiếp theo, mô hình luôn được cung cấp đầu vào là **từ chuẩn xác tuyệt đối** (ground-truth) từ dữ liệu huấn luyện, bất kể ở bước trước đó mô hình dự đoán đúng hay sai. Mô hình *"chưa bao giờ được tiếp xúc"* với các câu do chính nó tự sinh ra có lỗi.

- Khi suy luận / triển khai (Inference): Không còn "thầy giáo" (ground-truth) đứng cạnh chỉ lỗi. Mô hình bắt buộc phải tự tạo từng token dựa trên các token do chính nó tự sinh ra ở các bước trước đó.

- **Hậu quả:**
  - **(Compounding Errors):** Khi mô hình mắc một lỗi nhỏ ở bước 1, lỗi đó lập tức trở thành một phần đầu vào cho bước 2. Lỗi ở bước 2 tiếp tục làm hỏng bước 3, khiến các sai sót bé ban đầu nhân lên nhanh chóng.
  - (State Distribution Shift): Do chỉ học trên dữ liệu chuẩn, khi rơi vào một chuỗi câu chứa lỗi do chính mình tạo ra, mô hình rơi vào trạng thái *"lạ lẫm"* (chưa từng thấy lúc huấn luyện). Kết quả là mô hình hoàn toàn mất phương hướng và không thể tự sửa lỗi (cannot self-correct).

Key Algorithms Families Included

- SFT (Supervised Fine-Tuning): Cross-entropy Loss on demonstration targets
- Offline Preference Optimization: DPO, IPO, SLiC (updated based on static preference pairs)
- Off-Policy Teacher-Guided Transfer: Offline sequence-level knowledge distillation.

On-Policy Post-Training

Definition: Learning where the optimization updates are calculated on **learner-generated rollouts** produced dynamically by the current policy being trained.

Data Source: Real-time model outputs sampled during training, evaluated by reward models, unit tests, code execution environments, or process verifiers.

Core Strengths:

- **Eliminates Distribution Shift:** The model experiences its own failure modes and learns directly on the states it actually reaches during inference.
- **Policy Reshaping & Error Correction:** Effective at fine-tuning probability distributions over already-reachable paths, pruning reasoning errors, and improving calibration.

Core Weaknesses:

- **Exploration Bottleneck:** On-policy learning can only optimize trajectories the model is capable of generating. If a correct reasoning path has near-zero probability, on-policy exploration will almost never discover it without strong verifier/process guidance.
- **High Computational Cost:** Requires continuous rollout generation during training, making it computationally heavy.

Key Algorithm Families

- **RLHF / RLAIF / RLVR:** PPO, GRPO, REINFORCE (using reward signals or verifiable outcomes).
- **Online Preference Optimization:** Online DPO/PPO where reference pairs are dynamically generated and judged on-the-fly.
- **Process/Verifier-Guided Correction:** Process Reward Models (PRMs) providing step-by-step feedback on generated reasoning steps.
- **Iterative Refinement / Self-Correction:** Self-play, STaR-style reasoning loops, and multi-turn critique loops.

Work Together

Modern frontier post-training relies on a **coordinated multi-stage pipeline** combining both regimes rather than picking one over the other:

1. **Off-Policy Phase (Importing Behavior):** Uses SFT or distillation to expand the model's effective support, making valid formats and complex reasoning paths reachable.
2. **On-Policy Phase (Refining Behavior):** Uses RL or online preference learning on learner rollouts to reshape the policy, eliminate failure modes, and improve reliability on model-generated states.
3. **Consolidation Phase (Preserving Behavior):** Uses teacher-guided transfer or replay buffers to stabilize improvements and prevent catastrophic forgetting across training stages.

Supervision Interface

Định nghĩa: dùng để chỉ **hình thức mà các tín hiệu học tập (learning signals) được đính kèm** vào một tập hợp các trạng thái hoặc quỹ đạo dữ liệu cụ thể

Phân loại:

- Token targets: Đây là SI tiêu chuẩn trong **Supervised Fine-Tuning - SFT**. Mô hình được huấn luyện để dự đoán chính xác các token trong ground truth.
- **Pairwise or ranked preferences: SI** ở đây là ở đây là sự so sánh giữa các phản hồi "tốt hơn" và "tệ hơn”.
- **Reward-derived signals: Reward-derived signals:** Phổ biến trong **Học tăng cường từ phản hồi của con người (RLHF - Reinforcement Learning from Human Feedback)** hoặc **Học tăng cường với phần thưởng có thể xác thực (RLVR - Reinforcement Learning from Verifiable Rewards)**. Tín hiệu này thường là một giá trị vô hướng (scalar) đánh giá chất lượng tổng thể của một phản hồi
- **Verifier- or process-based feedback:** Tín hiệu được đính kèm vào từng bước trung gian trong quá trình suy luận (process supervision) thay vì chỉ đánh giá kết quả cuối cùng.
- **Teacher-guided targets:** Bao gồm các mục tiêu xác suất (logits), các vết dữ liệu được lọc hoặc các lý lẽ (rationales) do một mô hình mạnh hơn (giáo viên) cung cấp.

SFT

Định nghĩa

- **Bản chất:** SFT là quá trình huấn luyện tiếp theo một **Pretrained LLM** trên một tập dữ liệu bao gồm các cặp **(INSTRUCTION, OUTPUT)** theo cách thức có giám sát.
- **Nguồn gốc quỹ đạo (Trajectory provenance):** SFT được xếp vào nhóm **học ngoại chính sách (off-policy learning)** vì nó huấn luyện trên các quỹ đạo dữ liệu được cung cấp từ bên ngoài thay vì các lượt chạy (rollouts) do chính mô hình hiện tại tự tạo ra

- **Mục tiêu: Next-word prediction** (dự đoán từ tiếp theo) trong giai đoạn tiền đào tạo và mục tiêu tuân thủ hướng dẫn của người dùng (**Instruction following**)
- Supervision Interface: Token targets

Vai trò chức năng:

SFT không có một chức năng cố định mà thay đổi tùy thuộc vào mối quan hệ giữa dữ liệu giám sát và khả năng hiện tại của mô hình:

- **Effective support expansion:** Xảy ra khi dữ liệu huấn luyện đưa vào các cấu trúc quỹ đạo hoặc kiểu suy luận mới mà trước đó mô hình hiếm khi hoặc không thể tạo ra một cách đáng tin cậy
- **Policy reshaping:** Khi mô hình đã có năng lực tiềm ẩn, **SFT** đóng vai trò căn chỉnh định dạng (**Formatting**), phong cách hoặc lựa chọn trong số các hành vi đã có sẵn để phù hợp với sở thích người dùng

Ứng dụng và điểm mạnh

- SFT là nền tảng cho nhiều quy trình như: tinh chỉnh theo hướng dẫn (instruction tuning), thích ứng khả năng và tên miền (capability and domain adaptation), tinh chỉnh an toàn (safety tuning), và **tự khởi động bằng dữ liệu tổng hợp (synthetic-data bootstrapping)**.
- **Điểm mạnh:** Giúp thiết lập các hành vi hữu ích ban đầu một cách rộng rãi, nhập vào các cấu trúc quỹ đạo mới và căn chỉnh định dạng phản hồi một cách hiệu quả

Hạn chế và rủi ro

- **Sự không khớp về mức độ tiếp xúc (Exposure mismatch):** Đây là điểm yếu cốt lõi vì mô hình học trên các tiền tố (prefixes) của giáo viên nhưng khi triển khai lại phải tự tạo tiền tố cho chính mình.
- **Tính giòn (Brittleness):** Các hành vi có vẻ mạnh mẽ dưới các tiền tố được biên soạn có thể trở nên không ổn định khi mô hình tự thực hiện các phần tiếp theo.
- **Hao mòn hỗ trợ (Support attrition):** SFT có thể dẫn đến việc học quá mức (overfitting) các phong cách hẹp hoặc làm mất đi các khả năng đã có trước đó

(quên kiến thức).

- **Hạn chế sửa lỗi:** SFT khó có thể trực tiếp sửa chữa các lỗi chỉ phát sinh trong quá trình mô hình tự tạo phản hồi (lỗi rẽ nhánh tự thân)
- **Căn chỉnh bề mặt (Superficial Alignment):** Các thí nghiệm cho thấy ngay cả khi loại bỏ các thành phần ngữ nghĩa trong hướng dẫn hoặc đưa vào các ví dụ sai lệch, mô hình vẫn đạt hiệu suất tương đương. Điều này củng cố quan điểm rằng mô hình có thể chỉ đang nhận diện các khuôn mẫu bề mặt thay vì hiểu sâu sắc nhiệm vụ

Quy trình xây dựng dữ liệu

Mỗi thực thể trong tập dữ liệu **SFT** thường bao gồm ba yếu tố: **Instruction** (định nghĩa nhiệm vụ), **Input** (thông tin bổ sung tùy chọn) và **Anticipated output** (phản hồi mong đợi). Có 3 phương pháp chính:

1. **Human-crafted data:** Thu thập thủ công hoặc tích hợp từ các tập dữ liệu NLP có sẵn
2. **Synthetic data via Distillation:** Sử dụng các mô hình giáo viên mạnh hơn để tạo phản hồi cho các câu lệnh, sau đó huấn luyện student model.
3. **Synthetic data via Self-improvement:** Mô hình tự tạo ra các hướng dẫn và phản hồi mới dựa trên một số ít **Seed instructions** ban đầu để tự mở rộng khả năng của chính mình
   Quy trình thường bao gồm 4 bước chính:
   - **Bước 1: Thu thập dữ liệu hạt giống (Seed data):** Thu thập một lượng nhỏ nhiệm vụ do con người viết (ví dụ: 175 nhiệm vụ) để làm dữ liệu mồi.
   - **Bước 2: Tạo hướng dẫn mới:** Mô hình sử dụng các hướng dẫn hạt giống này làm ví dụ (few-shot prompt) để tự tạo ra các hướng dẫn mới thông qua học ngữ cảnh (in-context learning).
   - **Bước 3: Tạo phản hồi:** Với mỗi hướng dẫn mới được tạo ra, mô hình sẽ tự tạo câu trả lời tương ứng. Nếu nhiệm vụ yêu cầu thêm ngữ cảnh (như đọc hiểu), mô hình cũng sẽ tự tạo phần ngữ cảnh đó.
   - **Bước 4: Lọc dữ liệu:** Các cặp (hướng dẫn, phản hồi) sẽ được lọc qua một loạt các quy tắc hoặc mô hình để đảm bảo chất lượng trước khi dùng để tinh chỉnh (fine-tuning) lại chính mô hình đó.

RLHF (Reinforcement Learning Human Feedback)

RLHF (Reinforcement Learning from Human Feedback) là một trong những phương pháp (framework) phổ biến và quan trọng nhất hiện nay để **căn chỉnh (alignment)** các mô hình ngôn ngữ lớn (LLM) theo giá trị và mục đích của con ngườ

Một quy trình RLHF tiêu chuẩn thường bao gồm ba bước chính:

- **Giai đoạn 1: Supervised Fine-Tuning (SFT):** Mô hình được tinh chỉnh có giám sát trên một tập dữ liệu nhỏ gồm các chỉ dẫn và phản hồi chất lượng do con người viết để thiết lập năng lực cơ bản.
- **Giai đoạn 2: Huấn luyện Mô hình phần thưởng (Reward Model - RM):**
  - Mô hình tạo ra nhiều phản hồi cho cùng một câu hỏi.
  - Con người sẽ **xếp hạng (ranking)** các phản hồi này theo sở thích.
  - Một mô hình phần thưởng được huấn luyện dựa trên các ranking để học cách dự đoán điểm số sao cho phản hồi được con người ưu tiên sẽ có điểm cao hơn.
- **Giai đoạn 3: Tối ưu hóa chính sách bằng Học tăng cường (RL):** Sử dụng các kỹ thuật học tăng cường (PPO - Proximal Policy Optimzation) để tinh chỉnh mô hình SFT ban đầu. Mô hình sẽ học cách tạo ra các câu trả lời đạt điểm số cao nhất theo Reward Model.

Reward Model

- **Cấu trúc:** Thường chia sẻ cùng kiến trúc Transformer với mô hình ngôn ngữ gốc nhưng được thêm một lớp tuyến tính ở cuối để xuất ra một điểm số vô hướng (scalar score).
- **Độ chi tiết:** Các nghiên cứu mới đang chuyển dần từ chấm điểm cho toàn bộ câu trả lời sang chấm điểm ở mức độ **từng token (token-level)** hoặc từng bước suy luận để mang lại tín hiệu huấn luyện chi tiết hơn

Mục tiêu: Huấn luyện sao cho gia tăng xác suất của phản hồi được con người yêu thích hơn có điểm cao hơn các phản hồi còn lại, cũng như khoảng cách điểm của chúng.

How it wokrs:

Sau khi có tập các cặp dữ liệu so sánh từ con người, người ta dùng nó để huấn luyện **Reward Model (RM)**:

1. **Huấn luyện RM:** RM được học cách gán cho mỗi cặp (x, y) một con số thực $r(x, y)$ (điểm phần thưởng) sao cho:
   - Điểm của phản hồi được người chọn $r(x, y_w)$phải **cao hơn** điểm của phản hồi bị bác bỏ $r(x, y_l)$.
   - Điểm số này được ném qua hàm loss **Sigmoid** để khiến model chấm điểm đúng với cách chọn chọn của con người theo công thức Bradley-Terry:

$$P(y_w \succ y_l \mid x) = \frac{1}{1 + e^{-(r(x,y_w) - r(x,y_l))}} = \sigma\big(r(x, y_w) - r(x, y_l)\big)$$

2. **Dự đoán:** Sau khi huấn luyện xong, **Reward Model sẽ đóng vai trò như một "con người tự động"**. Nó có thể chấm điểm phần thưởng $r(x, y)$ cho hàng triệu câu trả lời.

Phân loại:

- Response level: Gán điểm cho toàn bộ câu trả lời
- Token level: Gán điểm cho từng token
- Multi-aspect: thay vì 1 điểm xuất ra 1 vector tổng hợp điểm cho nhiều tiêu chí khác nhau

Thuật toán PPO:

Definition: là thuật toán học tăng cường (RL) phổ biến nhất được sử dụng trong giai đoạn cuối của quy trình **RLHF,** đóng vai trò là bộ tối ưu hóa để tinh chỉnh mô hình ngôn ngữ (gọi là chính sách - Policy).

- **Mục tiêu:** Điều chỉnh các tham số của mô hình sao cho các câu trả lời mà nó tạo ra đạt được điểm số cao nhất từ Mô hình phần thưởng.
- **Cơ chế On-policy:** PPO hoạt động dựa trên các dữ liệu mô hình **tự tạo ra tại thời điểm đó** (fresh rollouts), thay vì học từ dữ liệu tĩnh có sẵn

Hàm mục tiêu (Objective Function)

$$J(\theta) = E_{x\sim D, y\sim\pi\theta}[r_\phi(x,y)] - \beta DKL[\pi_\theta \,||\, \pi_{ref}]$$

- **Thành phần 1 (Phần thưởng):** Khuyến khích mô hình tạo ra phản hồi khớp với sở thích con người.
- **Thành phần 2 (Phạt KL Divergence):** Đây là thành phần cực kỳ quan trọng. Nó ngăn chính sách mới (π_θ) đi quá xa so với mô hình gốc ban đầu chính là mô hình đầu ra của SFT được đóng băng trọng số (π_{ref}). Điều này giúp:
  - Tránh hiện tượng **Reward Hacking** (mô hình tìm ra kẽ hở để đạt điểm cao nhưng câu trả lời vô nghĩa).
  - Duy trì khả năng ngôn ngữ tự nhiên và kiến thức đã học được từ giai đoạn tiền huấn luyện.

Nhược điểm:

- Cần rất nhiều lượt tạo văn bản mới để học hiệu quả
- Độ phức tạp tính toán cao, duy nhiều nhiều model trong bộ nhớ ((Policy, Reference, Reward, Value)
- PPO rất khó để huấn luyện ổn định và dễ bị biến động nếu cấu hình không chuẩn

Thách thức & hạn chế

- **Chi phí cao:** Việc thuê con người xếp hạng hàng chục nghìn mẫu dữ liệu rất tốn kém và khó mở rộng.
- **Sở thích chủ quan:** Phản hồi của con người có thể không nhất quán hoặc bị ảnh hưởng bởi định kiến cá nhân, gây nhiễu cho mô hình.
- **Reward Hacking (Trục lợi phần thưởng):** Mô hình có thể tìm ra các "đường tắt" hoặc các mẫu câu chữ khiến Reward Model cho điểm cao nhưng thực tế không mang lại giá trị cho người dùng

DPO (Direct Preference Optimization)

DPO cho phép tối ưu hóa sở thích của con người mà **không cần huấn luyện một mô hình phần thưởng (Reward Model) riêng biệt** hay sử dụng các thuật toán học

tăng cường (RL) phức tạp như PPO

Phân loại

- **Chế độ học (Provenance):** DPO tiêu chuẩn được coi là **Off-policy** vì nó học trên các quỹ đạo dữ liệu được chuẩn bị sẵn từ bên ngoài.
- **Vai trò (Functional Role):** Nó chủ yếu đóng vai trò **Định hình chính sách (Policy Reshaping)** — tức là cải thiện hành vi bằng cách phân phối lại xác suất trong các vùng dữ liệu mà mô hình đã có thể tạo ra được, thay vì mở rộng năng lực mới

How it works

Trong RLHF truyền thống, phản hồi của con người được dùng để huấn luyện một **Mô hình phần thưởng (RM)** riêng biệt, sau đó RM này mới dạy lại mô hình ngôn ngữ thông qua Học tăng cường (PPO).

DPO đã thực hiện một bước đột phá về toán học:

- Nó chứng minh rằng chính mô hình ngôn ngữ có thể **tự suy ra phần thưởng ẩn** từ xác suất của các từ mà nó tạo ra.
- Thay vì dùng phản hồi con người để huấn luyện Reward, DPO đưa trực tiếp các cặp thắng/thua do con người chọn vào **hàm mất mát (loss function)** của mô hình.

Loss Function

- Nó điều chỉnh tham số mô hình sao cho **xác suất tạo ra phản hồi thắng** (y_w) **tăng lên** và **xác suất tạo ra phản hồi thua** (y_l) **giảm xuống**.
- Mô hình sẽ tự so sánh xác suất hiện tại của nó với một mô hình tham chiếu (thường là bản SFT ban đầu) để đảm bảo nó không thay đổi quá mức và vẫn giữ được khả năng ngôn ngữ tự nhiên

$$LDPO(\pi_\theta; \pi_{ref}) = -E_{(x,y_w,y_l)\sim D}[log\sigma(\beta log\frac{\pi_\theta(y_w \mid x)}{\pi_{ref}(y_w \mid x)} - \beta log\frac{\pi_\theta(y_l \mid x)}{\pi_{ref}(y_l \mid x)}]$$

Trong đó:

- π_θ: Chính sách đang được huấn luyện.

- πref: Chính sách tham chiếu (thường là mô hình SFT đã đóng băng) để ngăn mô hình đi quá xa khỏi phân phối ngôn ngữ chuẩn.
- β: Siêu tham số điều chỉnh mức độ phạt sự sai lệch so với mô hình tham chiếu (tương đương với KL regularization trong RLHF).
- σ: Hàm sigmoid để chuyển đổi sự chênh lệch phần thưởng thành xác suất

Ưu điểm khi so với RLHF:

- **Tiết kiệm tài nguyên:** DPO không cần lưu giữ nhiều mô hình (như Critic model, Reward model) trong bộ nhớ GPU cùng một lúc, giúp giảm đáng kể chi phí tính toán.
- **Loại bỏ Reward Hacking:** Vì không sử dụng một mô hình phần thưởng riêng biệt (vốn có thể bị mô hình ngôn ngữ "đánh lừa" bằng các mẹo về phong cách), DPO giảm thiểu rủi ro mô hình học được các hành vi trục lợi phần thưởng
- **Tính ổn định:** PPO rất nhạy cảm với các siêu tham số và dễ bị sụp đổ (mode collapse). DPO là một bài toán tối ưu hóa lồi, dễ hội tụ và ổn định hơn nhiều.